Datensätze bändigen & visualisieren mit R

B. Philipp Kleer

11. Oktober 2021

Tabellen publizierbar erstellen mit `gt`

Start

Das *package* `gt` (*grammar of tables*) inkludiert hilfreiche Funktionen, um Tabellen aus R in ein Format zu exportieren, das in wissenschaftlichen Arbeiten oder bei Präsentationen genutzt werden kann.

Das Paket ist umfassend und hier werden nur einführende Schritte dargestellt, die aber für erste Projekte im BA-Studium hilfreich sind. Die genaue Dokumentation findet sich in der **Benutzerdokumentation (https://gt.rstudio.com/)**.

Die generelle Funktionslogik erfolgt bei `gt` wie folgt:

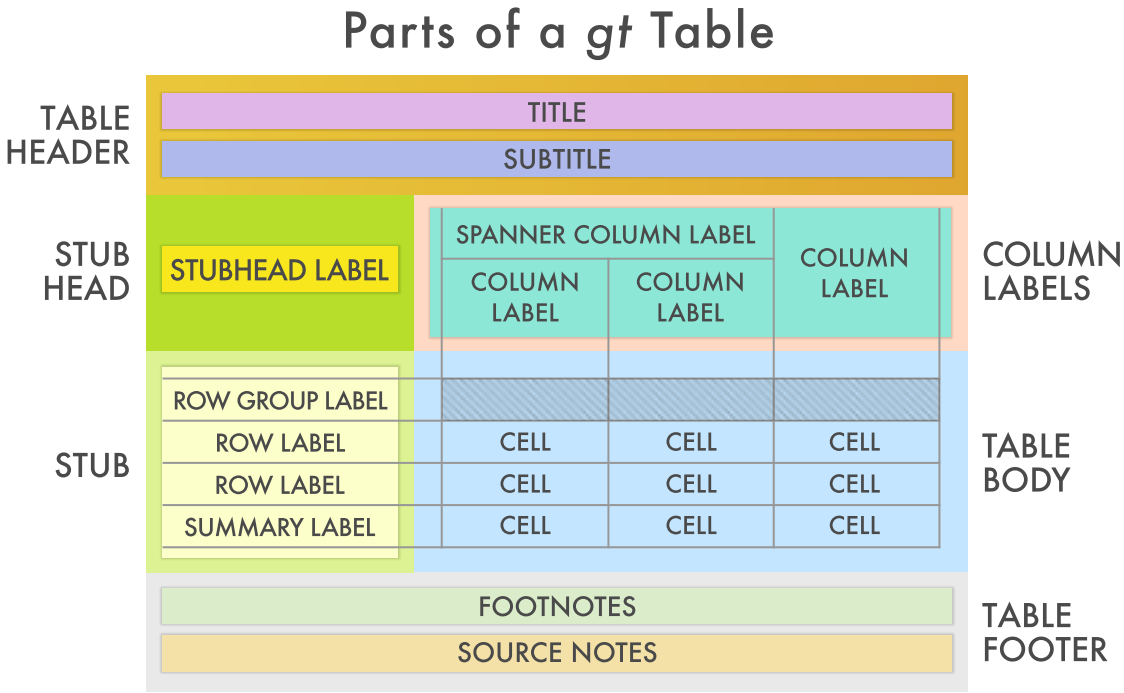

All diese verschiedenen Felder können einzeln angesprochen werden und verändert werden.

Bevor wir nun mit den Beispielen starten, müssen wir das *package* selbst laden als auch `tidyverse`.

```
# falls noch nicht installiert
# install.packages("gt",
#                  dependencies = TRUE
#                  )

# install.packages("tidyverse",
#                  dependencies = TRUE
#                  )

library("gt")
library("tidyverse")
```

Eine einfache Tabelle

Bevor wir nun Kreuztabellen darstellen, machen wir eine einfache Tabelle. Wir wollen zum Beispiel die Häufigkeiten für die *Studienmotivation* ausgeben lassen (`mot`).

```
table(uni$mot)
```

```
  0   1   2   3   4   5   6   7   8   9
105  93  81 110 116  93  88 108  91 115
```

Zuerst müssen wir mit `tidyverse` ein *tibble* schaffen, dass wir an `gt` übergeben können. Dazu wählen wir aus dem Datensatz die Variable `mot` aus, gruppieren die Daten nach `mot` und bilden dann mit summarize die jeweilige Summe unter den Ausprägungen der Variable `mot` (Funktion `n()`). Mit `gt()` erstellen wir dann die Tabelle:

```
uni %>%
  select(mot) %>%
  group_by(mot) %>%
  summarise(n = n()) %>%
  gt()
```

mot	n
0	105
1	93
2	81
3	110
4	116
5	93
6	88

mot	n
7	108
8	91
9	115

Jetzt ist das Format noch etwas unhandlich für Berichte oder Abschlussarbeiten und daher nutzen wir eine weitere Funktion aus `tidyverse`, nämlich `pivot_wider()`. Mit `pivot_wider()` können wir die Tabelle neu ordnen. Hierbei geben wir dann an, dass die Spaltennamen die Ausprägungen von `mot` sind und die Werte (also der Inhalt der ersten und einzigen Zeile) aus der vorherigen Spalte `n` entnommen werden.

```
uni %>%
  select(mot) %>%
  group_by(mot) %>%
  summarise(n = n()) %>%
  pivot_wider(names_from = mot,
              values_from = n
              ) %>%
  gt()
```

0	1	2	3	4	5	6	7	8	9
105	93	81	110	116	93	88	108	91	115

Fertig ist die Darstellung der absoluten Häufigkeiten der Variable `mot`. Dies sieht schon viel schöner aus als in der R Konsole (und ist auch als Bild exportierbar, dazu später mehr). Bevor nun einzelne Formatierungsmöglichkeiten in `gt` gezeigt werden, gehen wir über zu Kreuztabellen und zur Ausgabe prozentualer Häufigkeiten.

Kreuztabelle

Wir nehmen wieder ein Beispiel aus dem Trainingsdatensatz `uni`. Wir möchten eine Kreuztabelle zwischen Studienort (`city`) und Studienfach (`study`) erstellen. Wir möchten wissen, wie viele Personen jeweils in den einzelnen Städten die spezifischen Fächer studieren.

```
example
```

```
                    Gießen Marburg Frankfurt
  Political Science      70      72        78
  Sociology              88      94        81
  Educational Science    95      96        74
  Psychology             85      88        79
```

Wir wir sehen ist die originäre R Ausgabe nicht gut visuell dargestellt und auch die bisher genutzten Pakete erhöhten zwar die *readibility* in der Konsole, konnten aber nicht den Export unterstützen. Für die Weiterverwendung in anderen Paketen eignet sich daher das *package* `gt`, mit dem wir Bilddateien aus den Tabellen erstellen können.

Hierbei greifen wir auf das Paket `tidyverse` zurück, in dem wir die Daten für das *package* `gt` manipulieren. Nehmen wir das Beispiel einer Kreuztabelle zwischen Studienort und Studienfach von oben. Zuerst selektieren wir zur Vereinfachung den Datensatz auf die zwei genutzten Variablen mit `select()`. Anschließend gruppieren wir die Daten mit `group_by()`. Danach nutzen wir `summarize()`, um die Summen der einzelnen Kombinationen zu bilden (also die späteren Zellen der Tabelle). Bevor wir dann die Funktion `gt()` aufrufen, nutzen wir eine weitere Funktion aus `tidyverse`, nämlich `pivot_wider()`.

```
uni %>%
  select(study,
         city
         ) %>%
  group_by(city,
           study
           ) %>%
  summarise(n = n()) %>%
  pivot_wider(names_from = city,
              values_from = n
              )
```

study <fct>	**Gießen** <int>	**Marburg** <int>	**Frankfurt** <int>
Political Science	70	72	78
Sociology	88	94	81
Educational Science	95	96	74
Psychology	85	88	79

4 rows

Wir sehen, dass wir nun ein *tibble* haben, der in der ersten Spalte die Ausprägungen von `study` hat, und die zweite bis vierte Spalte stellen die Ausprägungen von `city` dar. In den einzelnen Feldern befindet sich die Summe der einzelnen Paare.

Kreuztabelle mit `gt`

Als nächstes werden wir jetzt dann die Funktion `gt()` aufrufen:

```
uni %>%
  select(study,
         city
         ) %>%
  group_by(city,
           study
           ) %>%
  summarise(n = n()) %>%
  pivot_wider(names_from = city,
              values_from = n
              ) %>%
  gt()
```

study	Gießen	Marburg	Frankfurt

study	Gießen	Marburg	Frankfurt
Political Science	70	72	78
Sociology	88	94	81
Educational Science	95	96	74
Psychology	85	88	79

Nun sehen wir die erste mit `gt` erzeugte Kreuztabelle. Bevor wir nun in die Formatierung der Tabelle gehen, schaffen wir erst prozentuale Ausgaben. **Wichtig hierbei**: Die Konvention ist, dass wir Spaltenprozente erstellen.

```
uni %>%
  select(study,
         city
         ) %>%
  group_by(city,
           study
           ) %>%
  summarise(n = n()) %>%
  mutate(prop = n / sum(n))%>%   # neue prozentualer Anteil nach Spalten!
  pivot_wider(names_from = city,
              values_from = prop
              ) %>%
  gt()
```

study	n	Gießen	Marburg	Frankfurt
Political Science	70	0.2071006	NA	NA
Sociology	88	0.2603550	NA	NA
Educational Science	95	0.2810651	NA	NA
Psychology	85	0.2514793	NA	NA
Political Science	72	NA	0.2057143	NA
Sociology	94	NA	0.2685714	NA
Educational Science	96	NA	0.2742857	NA
Psychology	88	NA	0.2514286	NA
Political Science	78	NA	NA	0.2500000
Sociology	81	NA	NA	0.2596154
Educational Science	74	NA	NA	0.2371795
Psychology	79	NA	NA	0.2532051

Das Ergebnis irritiert etwas, denn wir haben doppelte Spalten. Dies liegt daran, dass wir weiterhin noch die absoluten Zahlen als Spalte (`n`) mit übergeben haben. Diese schließen wir einfach über `subset()` aus:

```
uni %>%
  select(study,
         city
         ) %>%
  group_by(city,
           study
           ) %>%
  summarise(n = n()) %>%
  mutate(prop = n / sum(n))%>%   # neue prozentualer Anteil nach Spalten!
  subset(select = c("city",
                    "study",
                    "prop"
                    )
         ) %>% # die zwei Variablen und prop!
  pivot_wider(names_from = city,
              values_from = prop
              ) %>%
  gt()
```

study	Gießen	Marburg	Frankfurt
Political Science	0.2071006	0.2057143	0.2500000
Sociology	0.2603550	0.2685714	0.2596154
Educational Science	0.2810651	0.2742857	0.2371795
Psychology	0.2514793	0.2514286	0.2532051

Nun haben wir also eine Kreuztabelle mit absoluten Häufigkeiten und eine mit relativen Häufigkeiten. In den nächsten Schritten wird die Tabelle formatiert.

Formatierungen in `gt`

Um die Tabellen nun zu formatieren, speichern wir diese zuerst in einem Objekt: Denn R ist objektorientiert! Wir nehmen die absolute Häufigkeitstabelle der Variable `mot` und die prozentuale Kreuztabelle ziwschen `city` und `study` . **Wichtig hierbei**: Erinnere dich an die Abbildung zu Beginn, in der alle einzelnen Bereiche einer `gt` -Tabelle benannt waren!

```
single ← uni %>%
  select(mot) %>%
  group_by(mot) %>%
  summarise(n = n()) %>%
  pivot_wider(names_from = mot,
              values_from = n
              ) %>%
  gt()

cross ← uni %>%
  select(study,
         city
         ) %>%
  group_by(city,
           study
           ) %>%
  summarise(n = n()) %>%
  mutate(prop = n / sum(n))%>%
  subset(select = c("city",
                    "study",
                    "prop"
                    )
         ) %>%
  pivot_wider(names_from = city,
              values_from = prop
              ) %>%
  gt()
```

Titel ändern

Zuerst fügen wir der Häufigkeitstabelle nun einen Titel hinzu, damit klar ist, um was für Daten es sich handelt.

```
single %>%
  tab_header(title = "Abs. Häufigkeit von Studienmotivation")
```

Abs. Häufigkeit von Studienmotivation									
0	1	2	3	4	5	6	7	8	9
105	93	81	110	116	93	88	108	91	115

Alignment ändern

Wie wir sehen, sind die Spalten rechts ausgerichtet, dies können wir ebenfalls ändern und zentrieren es nun:

```
single %>%
  tab_header(title = "Abs. Häufigkeit von Studienmotivation") %>%
  cols_align(align = c("center"))  # auch möglich: auto, left, right
```

Abs. Häufigkeit von Studienmotivation									
0	1	2	3	4	5	6	7	8	9
105	93	81	110	116	93	88	108	91	115

Quelle & Fußnote hinzufügen

Oft werden unter Tabellen Quellen oder Anmerkungen angegeben, dies können wir auch ganz einfach mit `gt` machen:

```
single %>%
  tab_header(title = md("Abs. Häufigkeit von Studienmotivation")) %>%
  cols_align(align = c("center")) %>%
  tab_source_note(source_note = "Quelle: eigene Erhebung.") %>%
  tab_source_note(source_note = md("Anmerkungen: Mit *md()* können Textformatierungen wie in
Markdown vorgenommen **werden**."))
```

Abs. Häufigkeit von Studienmotivation									
0	1	2	3	4	5	6	7	8	9
105	93	81	110	116	93	88	108	91	115
Quelle: eigene Erhebung.									
Anmerkungen: Mit *md()* können Textformatierungen wie in Markdown vorgenommen **werden**.									

Manchmal möchte man zu einzelnen Werten auch eine Fußnote einfügen. Wir fügen jetzt eine Fußnote zum Wert *0* ein. Hierbei muss unterschieden werden, ob im `cells body` oder in den `column labels` eine Fußnote hinzugefügt werden soll. Wir fügen die erste Fußnote in ein `column label` ein und die zweite Fußnote in eine Zelle der Tabelle. Wenn wir im `column label` eine Fußnote hinzufügen wollen, benutzen wir in der Funktion `tab_footnote()` im Argument `locations` die Funktion `cells_column_labels()` und geben unter `columns` die spezifische Spalte an. Wenn wir in einer Zelle eine Fußnote setzen wollen, nutzen wir im Argument `locations` die Funktion `cells_body()` und geben dort in den Argumenten `columns` und `rows` die Position(en) an. Dies können auch mehrere sein (mit `c()` oder `1:3`):

```
single %>%
  tab_header(title = md("Abs. Häufigkeit von Studienmotivation")) %>%
  cols_align(align = c("center")) %>%
  tab_source_note(source_note = "Quelle: eigene Erhebung.") %>%
  tab_source_note(source_note = md("Anmerkungen: Mit *md()* können Textformatierungen vorgen
ommen **werden**.")) %>%
  tab_footnote(footnote = md("Ein Wert von *0* bedeutet **keinerlei Studienmotivation**."),
               locations = cells_column_labels(columns = "0")
               ) %>%
  tab_footnote(footnote = md("**Dies ist einfach nur ein Test.**"),
               locations = cells_body(columns = 7,
                                      rows = 1
                                      )
               )
```

Abs. Häufigkeit von Studienmotivation									
0[1]	1	2	3	4	5	6	7	8	9
105	93	81	110	116	93	88[2]	108	91	115

[1] Ein Wert von *0* bedeutet **keinerlei Studienmotivation**.

[2] ***Dies ist einfach nur ein Test.***

Quelle: eigene Erhebung.

Anmerkungen: Mit *md()* können Textformatierungen vorgenommen **werden**.

Spaltenbreite ändern

Als kleineres Manko sehen wir jetzt noch, dass die Spalten unterschiedlich breit sind. Dies können wir über `cols_width()` ändern. Hierbei können wir einzelnen Spalten aufrufen oder einen Bereich an Spalten festlegen. Wir könnten z.B. die Breite von Spalte 4 erhöhen. Hierzu nutzen wir die Hilfsfunktion `px()`, die die Größe in Pixel angibt.

```
single %>%
  tab_header(title = md("Abs. Häufigkeit von Studienmotivation")) %>%
  cols_align(align = c("center")) %>%
  tab_source_note(source_note = "Quelle: eigene Erhebung.") %>%
  tab_source_note(source_note = md("Anmerkungen: Mit *md()* können Textformatierungen vorgen
ommen **werden**.")) %>%
  tab_footnote(footnote = md("Ein Wert von *0* bedeutet **keinerlei Studienmotivation**."),
               locations = cells_column_labels(columns = "0")
               ) %>%
  tab_footnote(footnote = md("***Dies ist einfach nur ein Test.***"),
               locations = cells_body(columns = 7,
                                      rows = 1
                                      )
               ) %>%
  cols_width(4 ~ px(80))
```

Abs. Häufigkeit von Studienmotivation									
0[1]	1	2	3	4	5	6	7	8	9
105	93	81	110	116	93	88[2]	108	91	115

[1] Ein Wert von *0* bedeutet **keinerlei Studienmotivation**.

[2] ***Dies ist einfach nur ein Test.***

Quelle: eigene Erhebung.

Anmerkungen: Mit *md()* können Textformatierungen vorgenommen **werden**.

Am häufigsten passt man die Breite aller Spalten an, damit die Tabelle gleichmäßig ist: Dies geschieht über die Funktion `everything()`:

```
single %>%
  tab_header(title = md("Abs. Häufigkeit von Studienmotivation")) %>%
  cols_align(align = c("center")) %>%
  tab_source_note(source_note = "Quelle: eigene Erhebung.") %>%
  tab_source_note(source_note = md("Anmerkungen: Mit *md()* können Textformatierungen vorgen
ommen **werden**.")) %>%
  tab_footnote(footnote = md("Ein Wert von *0* bedeutet **keinerlei Studienmotivation**."),
               locations = cells_column_labels(columns = "0")
               ) %>%
  tab_footnote(footnote = md("***Dies ist einfach nur ein Test.***"),
               locations = cells_body(columns = 7,
                                      rows = 1
                                      )
               ) %>%
  cols_width(everything() ~ px(45))
```

Abs. Häufigkeit von Studienmotivation									
0[1]	1	2	3	4	5	6	7	8	9
105	93	81	110	116	93	88[2]	108	91	115

[1] Ein Wert von *0* bedeutet **keinerlei Studienmotivation**.

[2] ***Dies ist einfach nur ein Test.***

Quelle: eigene Erhebung.

Anmerkungen: Mit *md()* können Textformatierungen vorgenommen **werden**.

Schriftart & Schriftgröße ändern

Innerhalb von `tab_options()` gibt es eine Vielzahl von Optionen. Um Schriftarten zu ändern, muss man zuvor das *package* `extrafont` laden.

```
install.packages("extrafont",
                 dependencies = TRUE
                 )

library("extrafont")

#for mac
loadfonts(quiet = TRUE)

# for windows
loadfonts(device = "pdf",  #windows user use "win"
          quiet = TRUE
          )
```

So könnten wir die folgenden Anpassungen zum Beispiel vornehmen. Verändere den Code in der Funktion `tab_options()` einfach stellenweise, um zu sehen, was sich in der Darstellung ändert:

```
single %>%
  tab_header(title = md("Abs. Häufigkeit von Studienmotivation")) %>%
  cols_align(align = c("center")) %>%
  tab_source_note(source_note = "Quelle: eigene Erhebung.") %>%
  tab_source_note(source_note = md("Anmerkungen: Mit *md()* können Textformatierungen vorgen
ommen **werden**.")) %>%
  tab_footnote(footnote = md("Ein Wert von *0* bedeutet **keinerlei Studienmotivation**"),
               locations = cells_body(columns = c(1,
                                                  5
                                                  ),
                                      rows = 1
                                      )
               ) %>%
  cols_width(everything() ~ px(45)) %>%
  tab_options(table.font.names = "Candara",
              table.font.size = 12,
              heading.title.font.size = 14,
              column_labels.font.size = 13,
              source_notes.font.size = 9
              )
```

Abs. Häufigkeit von Studienmotivation									
0	1	2	3	4	5	6	7	8	9
105[1]	93	81	110	116[1]	93	88	108	91	115

[1] Ein Wert von *0* bedeutet **keinerlei Studienmotivation**

Quelle: eigene Erhebung.

Anmerkungen: Mit *md()* können Textformatierungen vorgenommen **werden**.

Dies stellt nur einen Ausschnitt der Funktionsmöglichkeiten von `gt` dar. Es können auch einzelne Zellen spezifisch farbig gestaltet werden und auch nach einer weiteren Variable dargestellt werden. Dazu ist ein Blick in die **Benutzerdokumentation (https://gt.rstudio.com/)** hilfreich.

Anpassungen bei Kreuztabellen

Nun wollen wir abschließend noch die Kreuztablle anpassen. Wir übernehmen die oben eingeführten Anpassungen für den Title, die Spaltenbreite und die Quelle. Die erste Spalte machen wir nun aber breiter als die anderen. Auch richten wir die erste Spalte links aus (wie nach Konvention üblich).

```
cross %>%
  tab_header(title = md("Studienort & Studienwahl")) %>%
  cols_align(align = "left",
             columns = study
             ) %>%
  cols_align(align = "center",
             columns = c("Gießen",
                         "Marburg",
                         "Frankfurt"
                         )
             ) %>%
  tab_source_note(source_note = "Quelle: eigene Erhebung.") %>%
  cols_width(study ~ px(150),
             everything() ~ px(100)
             )
```

Studienort & Studienwahl			
study	Gießen	Marburg	Frankfurt
Political Science	0.2071006	0.2057143	0.2500000
Sociology	0.2603550	0.2685714	0.2596154
Educational Science	0.2810651	0.2742857	0.2371795
Psychology	0.2514793	0.2514286	0.2532051
Quelle: eigene Erhebung.			

Was wir an dieser Stelle noch anpassen wollen, ist das die Zellen jeweils auf zwei Nachkommastellen gerundet werden. Dazu nutzen wir `fmt()`. Mit dem Argument `columns` bestimmen wir in welchen Zeilen gerundet werden soll, mit dem Argument `decimals` legen wir die Dezimalstellen fest und wer das Dezimalzeichen ändern möchte, kann dies im Argument `dec_mark` machen (dann auch `sep_mark` (Tausenderzeichen) ändern:

```
cross %>%
  tab_header(title = md("Studienort & Studienwahl")) %>%
  cols_align(align = "left",
             columns = study
             ) %>%
  cols_align(align = "center",
             columns = c("Gießen",
                         "Marburg",
                         "Frankfurt"
                         )
             ) %>%
  tab_source_note(source_note = "Quelle: eigene Erhebung.") %>%
  cols_width(study ~ px(150),
             everything() ~ px(100)
             ) %>%
  fmt_number(columns = c(2:4),
             decimals = 2,
             dec_mark = ",",
             sep_mark = "."
             )
```

Studienort & Studienwahl			
study	Gießen	Marburg	Frankfurt
Political Science	0,21	0,21	0,25
Sociology	0,26	0,27	0,26
Educational Science	0,28	0,27	0,24
Psychology	0,25	0,25	0,25
Quelle: eigene Erhebung.			

Bevor wir die Einführung ändern möchten wir noch den *Header* in der ersten Spalte ändern. Dies können wir über `cols_label()`:

```
cross %>%
  tab_header(title = md("Studienort & Studienwahl")) %>%
  cols_align(align = "left",
             columns = study
             ) %>%
  cols_align(align = "center",
             columns = c("Gießen",
                         "Marburg",
                         "Frankfurt"
                         )
             ) %>%
  tab_source_note(source_note = "Quelle: eigene Erhebung.") %>%
  cols_width(study ~ px(150),
             everything() ~ px(100)
             ) %>%
  fmt_number(columns = c(2:4),
             decimals = 2,
             dec_mark = ",",
             sep_mark = "."
             ) %>%
  cols_label(study = "Studienfach")
```

Studienort & Studienwahl			
Studienfach	Gießen	Marburg	Frankfurt
Political Science	0,21	0,21	0,25
Sociology	0,26	0,27	0,26
Educational Science	0,28	0,27	0,24
Psychology	0,25	0,25	0,25
Quelle: eigene Erhebung.			

Auch dabei können mit `md()` Formatierungen vorgenommen werden:

```
cross %>%
  tab_header(title = md("Studienort & Studienwahl")) %>%
  cols_align(align = "left",
             columns = study
             ) %>%
  cols_align(align = "center",
             columns = c("Gießen",
                         "Marburg",
                         "Frankfurt"
                         )
             ) %>%
  tab_source_note(source_note = "Quelle: eigene Erhebung.") %>%
  cols_width(study ~ px(150),
             everything() ~ px(100)
             ) %>%
  fmt_number(columns = c(2:4),
             decimals = 2,
             dec_mark = ",",
             sep_mark = "."
             ) %>%
  cols_label(study = md("**Studien-**<br>*fach*"))
```

Studienort & Studienwahl			
Studien- *fach*	Gießen	Marburg	Frankfurt
Political Science	0,21	0,21	0,25
Sociology	0,26	0,27	0,26
Educational Science	0,28	0,27	0,24
Psychology	0,25	0,25	0,25
Quelle: eigene Erhebung.			

So, für die Einführung in das *package* `gt` ist dies ausreichend. Insbesondere, wenn man eine dritte Gruppenvariable hinzufügt, bietet `gt` gute Möglichkeiten direkt in R publizierbare Tabellen zu generieren.

Bevor ihr geht, speichert!

Anstatt aus dem Viewer die Dateien zu speichern, kann man diese auch direkt über `gtsave()` speichern. Dazu gibt man einfach den Dateinamen ein und R speichert das Objekt im *Working Directory*.

```
cross %>%
  tab_header(title = md("Studienort & Studienwahl")) %>%
  cols_align(align = "left",
             columns = study
             ) %>%
  cols_align(align = "center",
             columns = c("Gießen", "Marburg", 'Frankfurt')) %>%
  tab_source_note(source_note = "Quelle: eigene Erhebung.") %>%
  cols_width(study ~ px(150),
             everything() ~ px(100)
             ) %>%
  fmt_number(columns = c(2:4),
             decimals = 2
             ) %>%
  cols_label(study = md("**Studien-**<br>*fach*")) %>%
  gtsave("./pics/mein-erster-gt-plot.png") # auch .html -Table möglich
```

Studienort & Studienwahl			
Studien- *fach*	Gießen	Marburg	Frankfurt
Political Science	0.21	0.21	0.25
Sociology	0.26	0.27	0.26
Educational Science	0.28	0.27	0.24
Psychology	0.25	0.25	0.25
Quelle: eigene Erhebung.			

Das war's!

Die Labs findet ihr in der RStudio Cloud unter `task gt`.